

## Висновки

### Проект: Аналітика поїздок NYC Yellow Taxi (січень–травень 2026)

#### 1. Результати очищення даних

Вихідний датасет містив 18 999 282 записи за п'ять місяців (січень–травень 2026). Після багатоетапного очищення збережено 18 074 891 поїздки (95.1%) — видалено лише реально невалідні записи.

Розбивка видалень:

- Дати поза межами діапазону (биті 2001/2008 роки): 15 рядків
- Невалідні гроші ( $\text{total\_amount} \leq 0$  або  $\text{fare\_amount} < 0$ ): ~121 тис.
- Нульова або абсурдна відстань (0 або  $> 100$  миль): ~577 тис.
- Невалідна тривалість ( $\leq 0$  або  $> 180$  хв): ~237 тис.
- Дублікати: 0

Ключове рішення: ~25.3% рядків (4 812 280) мали відсутні значення одночасно в п'яти колонках (`passenger_count`, `RatecodeID`, `store_and_fwd_flag`, `congestion_surcharge`, `Airport_fee`). Оскільки фінансові поля в цих рядках валідні (середній тариф ~\$26, середня сума ~\$33), прийнято рішення зберегти ці поїздки, позначивши невідомі категорії міткою «Unknown». Видалення цієї групи через `dropna()` призвело б до втрати чверті датасету і суттєвого зміщення аналізу.

#### 2. Архітектура бази даних

Розроблено реляційну схему «зірка» у PostgreSQL 18:

- Факт-таблиця `fact_trips` — 18 074 891 запис, 15 полів
- Довідники: `dim_vendor` (4 вендори), `dim_payment` (7 типів оплати), `dim_ratecode` (7 тарифних кодів), `dim_zone` (265 зон Нью-Йорка)
- Обмеження цілісності: первинні та зовнішні ключі (PK/FK), обмеження NOT NULL, CHECK на коректність грошей, відстані й тривалості
- Аналітичні view: `v_daily_agg` (денна агрегація), `v_hourly` (погодинний профіль по місяцях), `v_zone_stats` (метрики по зонах і місяцях)

#### 3. Ключові бізнес-інсайти

##### 3.1 Динаміка попиту в часі

За п'ять місяців виконано понад 18 млн поїздок із загальною виручкою понад 540 млн доларів. Денна кількість поїздок коливається в межах 80–145 тисяч, з чітким тижневим циклом (провали у вихідні та на початку тижня).

На графіку виразно видно два різкі провали — орієнтовно 23 січня (~43 тис. поїздок, падіння на 65%) і 22 лютого (~23 тис., падіння на 82%). За датами це відповідає сильним снігопадам у Нью-Йорку. Це підтверджує, що попит на таксі

критично залежить від погодних умов: в екстремальні дні обсяг може скорочуватися до 5 разів.

Також спостерігається загальний висхідний тренд від січня до травня: навесні поїздок системно більше, ніж узимку, що відповідає туристичній і діловій сезонності Нью-Йорка.

### 3.2 Погодинний профіль попиту

Розподіл поїздок за годинами доби має класичний двогорбий профіль міста:

- Мінімум: 4–5 ранку (~146 тис. поїздок на місяць у цю годину)
- Ранковий підйом: різке зростання з 6:00 (початок робочого дня)
- Вечірній пік: максимум о 18:00 (~1 187 тис. поїздок) — години пік плюс вечірня активність
- Поступовий спад після 19:00 до нічного мінімуму

Практичний висновок: майже 40% усіх поїздок припадає на вікно 16:00–21:00. Це пряме обґрунтування для динамічного ціноутворення у вечірній час і посиленого забезпечення автомобілями у цей період.

### 3.3 Географія попиту (зони Нью-Йорка)

Попит критично сконцентрований у Манхеттені — топ-10 зон за поїздками знаходяться переважно там:

| Зона                  | Поїздок | Середній тариф |
|-----------------------|---------|----------------|
| Upper East Side South | 825 154 | \$14.03        |
| Upper East Side North | 750 800 | \$14.81        |
| Midtown Center        | 739 416 | \$18.14        |
| JFK Airport (Queens)  | 690 507 | \$61.77        |
| Midtown East          | 545 222 | \$17.04        |

Аеропортний парадокс: зона JFK Airport посідає 4-е місце за кількістю поїздок, але має середній тариф \$61.77 — у 4 рази вище, ніж типова міська поїздка (~\$15). Завдяки цьому сумарна виручка з JFK (~\$55 млн) є найвищою серед усіх зон, попри менший обсяг. Це демонструє принципову різницю між двома типами попиту: короткі міські поїздки (висока частота, низький чек) і довгі аеропортні (нижча частота, але в рази вища виручка на поїздку).

### 3.4 Способи оплати

| Тип оплати          | Кількість | Відсоток |
|---------------------|-----------|----------|
| Кредитна картка     | 969 421   | (66.2%)  |
| Unknown             | 4 403 865 | (24.4%)  |
| Готівка             | 1 578 624 | (8.7%)   |
| Dispute / No charge | 122 981   | (0.7%)   |

Кредитна картка домінує з великим відривом. Висока частка «Unknown» (24.4%) — системна особливість одного з вендорів, а не проблема якості даних.

#### 4. Обмеження аналізу

- Відсутні місяці: початково датасет не містив даних за січень і березень, що могло б ускладнити аналіз сезонності. Файли було завантажено і включено до аналізу.
- Чверть даних без категорій: ~25% поїздок не мають типу оплати, кількості пасажирів і тарифного коду — аналіз за цими вимірами охоплює лише ~75% записів. Це слід враховувати при інтерпретації відповідних зрізів.
- Відсутність зовнішніх даних: погодні події (сніг, дощ) ідентифіковані за характером провалів, але не підтверджені зовнішніми джерелами (наприклад, NOAA). Кореляційний аналіз з метаданими міг би зміцнити висновки.
- Тільки Yellow Taxi: аналіз не охоплює Uber, Lyft, FHV та інші види міського транспорту — тому висновки стосуються саме цього сегменту.